TRABAJO FINAL DE MÁSTER — Business Analytics e Inteligencia Artificial

Análisis multidimensional del estrés estudiantil mediante Business Analytics e Inteligencia Artificial con datos académicos, conductuales y textuales

Andrés Francisco García Grajales • Obed Isaí Alvarado Núñez • Roberto Mario Brochero López
Raúl Cervantes Iglesias • Santiago Nicolas Viuche Pinilla

Respuesta a la retroalimentación de la Entrega I

Este documento detalla las acciones correctivas aplicadas al modelo de datos y a la arquitectura analítica del proyecto en respuesta a la evaluación de la Entrega I. Cada sección reproduce la observación del tutor, describe la acción tomada y señala el entregable donde queda implementada.

A diferencia de una propuesta teórica de corrección, la arquitectura descrita está implementada y en funcionamiento: la base de datos se creó en MySQL (XAMPP/MariaDB) con las 19 tablas del modelo v2, se añadió una capa de vistas en esquema estrella para consumo en Power BI (versión definitiva en la sección 5, con los dos diseños del diagrama), y se cargaron los 334.318 registros de los doce datasets. La sección 6 documenta la verificación ejecutada sobre esos datos y la sección 7 el seguimiento de los compromisos en el Objetivo 2.

---

1. Renombrado de claves primarias

> *Observación: "que las tablas tengan un campo que es la clave que se llama registro_id… es bastante mejorable. Se debe renombrar esos campos a algo más legible e identificable."*

Acción aplicada: todas las claves primarias genéricas fueron sustituidas por identificadores semánticos que describen la entidad que identifican. Las claves naturales de los CSV se conservan donde existen, también con nombre legible:

Tabla	Clave anterior (v1)	Clave nueva (v2)
b1_academic_stress	registro_id	id_encuesta_estres
b1_anxiety	registro_id	id_encuesta_ansiedad
b1_mental_health_survey	registro_id	id_encuesta_salud_mental
b1_student_habits	student_id (natural)	id_estudiante (natural)
b2_social_media_sleep	user_id (natural)	id_usuario_red (natural)
b2_smmh	registro_id	id_respuesta_smmh
b2_lifestyle	registro_id	id_registro_estilo_vida
b3_dreaddit_post	post_frag_id	id_fragmento_post (natural)
b3_depression_student	registro_id	id_perfil_estudiante
b4_dass_respondente	respondente_id	id_respondente_dass
b4_dass_item	(respondente_id, item_num)	(id_respondente_dass, numero_item)

Tabla	Clave anterior (v1)	Clave nueva (v2)
b4_mental_health	registro_id	id_caso_salud_mental

Implementado en: modelo_datos_mysql_v2.sql (todas las FKs y índices actualizados en consecuencia; las dimensiones adoptan el mismo patrón: id_bloque, id_dataset, id_genero, etc.).

---

2. Dimensiones conformes: eliminación de los silos

> *Observación: "Diseñar el modelo físico vinculando las tablas de hechos únicamente a dimensiones de metadatos (dim_bloque o dim_dataset) genera silos insalvables. […] sí comparten atributos analíticos comunes (como la edad, el género o el nivel educativo). […] necesitáis Dimensiones Conformes tales como dim_demografica o dim_rango_edad. De lo contrario, en Power BI será imposible aplicar un filtro global de 'Mujeres de 18 a 25 años'."*

Acción aplicada: se incorporaron cuatro dimensiones conformes compartidas por las doce tablas de hechos. Se optó por dimensiones atómicas separadas (en lugar de una única dim_demografica) por ser el patrón recomendado en Power BI para segmentadores independientes:

- **dim_genero**: Masculino / Femenino / Otro / No reportado. Armoniza las codificaciones heterogéneas de las fuentes (cadenas en inglés, códigos numéricos 1/2/3 del DASS, identidades de texto libre).
- **dim_rango_edad**: <18, 18-25, 26-35, 36-50, >50, No reportado, con edad_min y edad_max. La banda 18-25 materializa el proxy de población estudiantil del proyecto.
- **dim_nivel_educativo**: Secundaria o menos / Grado universitario / Posgrado / No reportado, unificando los códigos del DASS, los grados de ansiedad y la encuesta universitaria.
- **dim_nivel_estres**: el constructo analítico unificado (sección 3).

Cada tabla de hechos incorpora las cuatro claves foráneas conformes. El miembro 'No reportado' (id=0) —práctica estándar en modelado dimensional— permite conformar también las fuentes anónimas (el corpus Dreaddit, que carece de demografía por diseño) sin excluirlas del modelo ni admitir nulos en las FKs. Además, el porcentaje de miembros 'No reportado' de cada dimensión documenta de forma medible la cobertura demográfica real de cada fuente.

La verificación de que los silos quedaron resueltos se ejecutó sobre la base de datos ya cargada y se detalla en la sección 6.

---

3. Marco conceptual de la capa analítica global

> *Observación: "Al tener escalas y variables objetivo tan variadas en cada bloque (un indicador binario en Reddit, puntuaciones numéricas continuas en DASS-42, niveles categóricos en encuestas), falta un planteamiento conceptual claro de qué se va a predecir o medir exactamente en la capa analítica global de la solución."*

Acción aplicada: se define formalmente el constructo unificado del proyecto —el nivel de estrés/malestar armonizado— como variable ordinal de tres niveles (Bajo / Moderado / Alto), materializada en la dimensión conforme dim_nivel_estres. Cada dataset mapea su variable objetivo nativa a este constructo mediante criterios explícitos, clínicamente fundamentados donde la escala lo permite, y documentados en la tabla de gobernanza dim_mapeo_estres del propio modelo:

Fuente	Variable nativa	Criterio de armonización
Academic Stress	Índice 1-5	1-2 Bajo · 3 Moderado · 4-5 Alto
Anxiety	GAD_T (0-21)	0-4 · 5-9 · 10-21 (umbrales clínicos GAD-7)
MH Survey / SMMH	Likert 1-5	1-2 · 3 · 4-5
Dreaddit	Etiqueta 0/1	0 Bajo · 1 Alto (etiquetado manual)
Depression Student	Yes/No	No Bajo · Yes Alto
DASS-42	score_estres (14-56)	14-28 · 29-39 · 40-56 (baremos DASS)
Mental Health (chanchal24)	Estrés creciente Yes/Maybe/No	No Bajo · Maybe Moderado · Yes Alto
Sintéticos (3 fuentes)	Niveles nativos	Mapeo directo; solo capa descriptiva (sección 4)

Con este marco, el planteamiento de cada objetivo queda preciso: en el Objetivo 2, cada modelo predice la variable objetivo nativa de su dataset (respetando el análisis independiente comprometido en la propuesta), y sus resultados se leen e interpretan en la capa armonizada común; en el Objetivo 3, dim_nivel_estres es la métrica transversal de todos los dashboards, comparable entre bloques. El proyecto deja de ser una suma de mini-proyectos: es una arquitectura hub-and-spoke donde las fuentes conservan su granularidad y naturaleza, pero convergen en un mismo constructo medible y filtrable.

---

4. Política sobre datasets sintéticos en el modelado

> *Observación: "si pensáis usarlos en la fase de modelado predictivo (Objetivo 2) […] las redes o modelos predictivos aprenderán relaciones matemáticas artificiales generadas por un software, restándole toda validez científica al entregable final del Máster."*

Acción aplicada: se formaliza la exclusión de los tres datasets sintéticos (student_habits_performance, social_media_sleep_stress_productivity y Mental_Health_Lifestyle) del modelado predictivo del Objetivo 2. La política queda grabada en el propio modelo de datos mediante la columna uso_modelado de dim_dataset (valores 'incluido'/'excluido'), de modo que la restricción es consultable y auditable, no solo declarativa: basta una consulta SQL para comprobar qué fuentes alimentan el modelado. El papel de estas tres fuentes queda acotado a:

- Caso de estudio de calidad del dato en el Objetivo 1: su detección como sintéticos es un resultado legítimo del EDA y así se documenta.
- Capa descriptiva de los dashboards del Objetivo 3, siempre rotulados como fuentes sintéticas, sin alimentar conclusiones sustantivas.

El Objetivo 2 se entrenó exclusivamente sobre las nueve fuentes con señal real (etiqueta 'incluido'), leyendo la política desde la propia base de datos (sección 7), con lo que se preserva la validez científica del entregable final.

---

5. Capa de consumo en esquema estrella (versión definitiva)

Diagnóstico. El modelo físico v2 es, en términos de modelado dimensional, una constelación con una rama en copo de nieve (hechos → dim_dataset → dim_bloque). Esa cadena es correcta en la base de datos, pero penaliza el rendimiento y complica el DAX en Power BI. La solución es la arquitectura

estándar en dos capas: la base conserva su normalización —íntegra y auditable— y seis vistas la aplanan para el consumo analítico: **vw_hechos_estres** (una única tabla de hechos) y cinco dimensiones planas (vw_dim_dataset, que absorbe dim_bloque como columna desnormalizada, y las cuatro conformes). Sin cadenas dimensión-dimensión, es el patrón recomendado para Power BI y la materialización del Dashboard Multidimensional exigido en la retroalimentación.

5.1 Diseño inicial y diseño actualizado

El esquema se documentó en dos versiones. La estructura de las vistas es idéntica; lo que cambia es lo que el diagrama permite verificar:

Aspecto	Diagrama inicial (Figura 1)	Diagrama actualizado (Figura 2)
Fuentes de datos	No se muestran: solo aparece la tabla de hechos.	Los 12 datasets, agrupados por bloque, con sus filas y una flecha hacia la tabla de hechos.
Total de registros	Indicaba 320.318 filas (cifra errónea: no coincide con ninguna suma de los datos).	334.318 filas = 140 + 13.464 + 87 + 1.000 + 11.000 + 481 + 3.000 + 2.834 + 715 + 502 + 39.767 + 261.328.
Datasets sintéticos	Sin distinguir.	Marcados (borde discontinuo y asterisco): se cargan para la capa descriptiva y quedan excluidos del modelado.
Linaje	No explicado.	Se indica que id_dataset identifica la fuente (1 a 12) y que b4_dass_item queda fuera por tener grano de ítem.
Estructura de vistas	6 vistas (1 hecho + 5 dimensiones).	Las mismas 6 vistas: no hay cambio estructural.

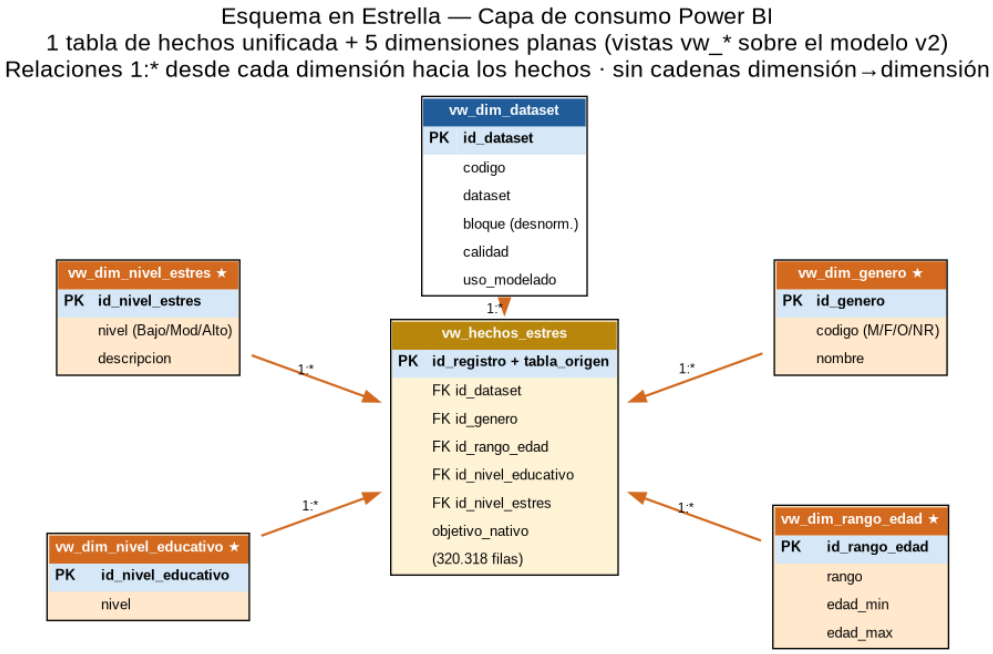


Figura 1. Diagrama inicial de la estrella (superado; se conserva como referencia).

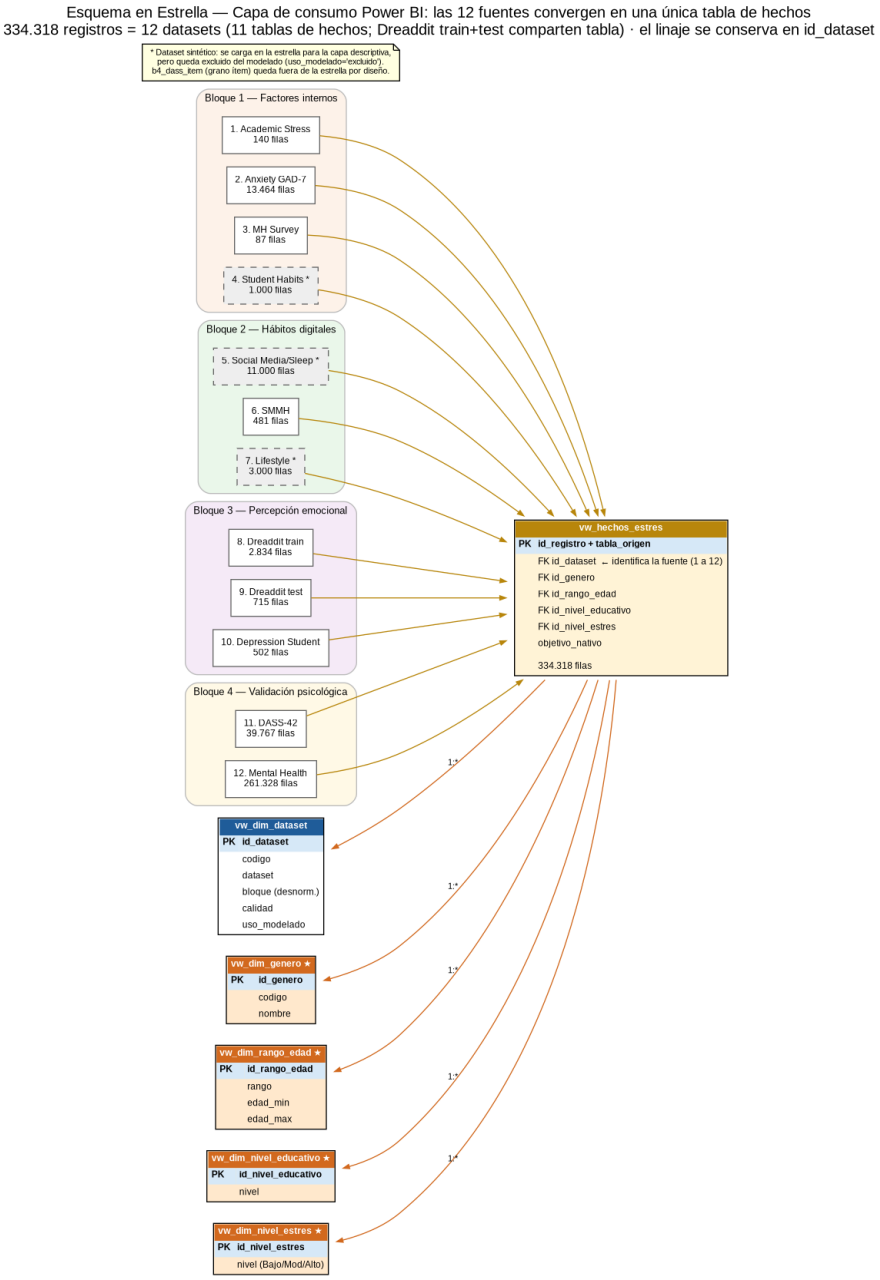


Figura 2. Diagrama actualizado y definitivo: las 12 fuentes convergen en vw_hechos_estres (334.318 registros).

5.2 Qué relaciona la estrella

vw_hechos_estres une con UNION ALL las **11 tablas de hechos**, que contienen los **12 datasets** (Dreaddit train y test comparten tabla y se distinguen por su id_dataset, 8 y 9). Cada fila conserva su fuente en id_dataset, que apunta a vw_dim_dataset, y comparte las cuatro claves conformes (género, rango de edad, nivel educativo y nivel de estrés) que permiten filtrar a la vez sobre todas las fuentes. Las filas por dataset proceden de la salida del notebook 07:

id	Dataset	Bloque	Tabla de origen	Filas	Calidad	Modelado
1	Academic Stress	Factores internos	b1_academic_stress	140	inferencial	incluido
2	Anxiety GAD-7	Factores internos	b1_anxiety	13.464	inferencial	incluido
3	MH Survey	Factores internos	b1_mental_health_survey	87	inferencial	incluido
4	Student Habits	Factores internos	b1_student_habits	1.000	técnico	excluido

id	Dataset	Bloque	Tabla de origen	Filas	Calidad	Modelado
5	Social Media/Sleep	Hábitos digitales	b2_social_media_sleep	11.000	técnico	excluido
6	SMMH	Hábitos digitales	b2_smmh	481	inferencial	incluido
7	Lifestyle	Hábitos digitales	b2_lifestyle	3.000	técnico	excluido
8	Dreaddit train	Percepción emocional	b3_dreaddit_post	2.834	inferencial	incluido
9	Dreaddit test	Percepción emocional	b3_dreaddit_post	715	inferencial	incluido
10	Depression Student	Percepción emocional	b3_depression_student	502	inferencial	incluido (en revisión)
11	DASS-42	Validación psicológica	b4_dass_respondente	39.767	inferencial	incluido
12	Mental Health	Validación psicológica	b4_mental_health	261.328	inferencial	incluido
	TOTAL		11 tablas	**334.318**		9 incluidos

Cuadre de totales. 334.318 registros menos los 15.000 de los tres datasets sintéticos (1.000 + 11.000 + 3.000) dan 319.318, la misma cifra que produce la tabla T1 del datawarehouse (Entrega 2) al unificar las nueve fuentes con señal real. La excepción deliberada es b4_dass_item (42 ítems por respondente): su grano es el ítem y no la persona, por lo que mezclarla rompería la estrella; permanece en la base para análisis psicométrico puntual.

5.3 Endurecimiento del SQL y versión definitiva

Al ejecutar la consulta de verificación sobre la vista, MariaDB devolvió el error **#1271 (mezcla ilegal de collations para la operación UNION)**: las ramas del UNION mezclaban textos con la collation de la conexión (CAST ... AS CHAR) y textos con la de las tablas (utf8mb4_unicode_ci). Se corrigió forzando COLLATE utf8mb4_unicode_ci en las 22 expresiones de texto del UNION. Tras la corrección, la consulta del tutor se ejecutó sin errores sobre la base cargada (sección 6).

Archivo definitivo: esquema_estrella_powerbi.sql (sustituye a cualquier copia anterior). Respecto a la primera versión:

- incorpora el COLLATE que evita el error #1271 (la primera versión lo produce al consultar la vista);
- apunta a la base real del proyecto, **tfm_estres_estudiantil_2**;
- añade dos consultas de verificación: V1 (12 filas, una por dataset) y V2 (total 334.318 y 319.318 en fuentes incluidas);
- **no cambia la estructura**: son las mismas 6 vistas. Por eso el diagrama actualizado no requiere un SQL nuevo.

---

6. Verificación sobre la base de datos en producción

La arquitectura no se entrega como diseño teórico: está implementada y poblada. El proceso completo se ejecutó en el siguiente orden:

- modelo_datos_mysql_v2.sql en phpMyAdmin: creación de la base y las 19 tablas, con las dimensiones conformes y de gobierno pobladas.
- esquema_estrella_powerbi.sql en phpMyAdmin: creación de las seis vistas de la capa de consumo.
- 07_carga_datos_mysql.ipynb en Jupyter: lectura de los doce CSV, cálculo de las claves conformes fila a fila, aplicación de las reglas de calidad del Objetivo 1 (exclusión de los cuatro fragmentos corruptos '#NAME?' de Dreaddit, filtrado de edades inválidas en DASS-42) y carga de 334.318 registros en las tablas de hechos.

Sobre esa base cargada se ejecutó el filtro exacto que la retroalimentación señalaba como imposible —mujeres, de 18 a 25 años, con nivel de estrés Alto— como una única consulta contra la vista de hechos, atravesando simultáneamente los cuatro bloques analíticos:

Bloque analítico	Dataset	Casos
Validación psicológica	DASS-42	6.799
Factores internos	Student Anxiety GAD-7	224
Factores internos	Student Habits vs Performance	183
Hábitos digitales	Social Media and Mental Health	110
Percepción emocional	Depression Student Dataset	65
Hábitos digitales	Mental Health Lifestyle	51
Factores internos	Student Mental Health Survey	14
TOTAL	**7 fuentes de los 4 bloques**	**7.446**

El resultado demuestra que el filtro demográfico global opera de forma transversal sobre fuentes que no comparten ningún identificador de persona, resolviendo el fallo crítico señalado. Las fuentes ausentes de la tabla lo están por una razón documentada y no por un defecto del modelo: el corpus Dreaddit es anónimo por diseño y el dataset de chanchal24 no registra edad, por lo que sus miembros conformes son 'No reportado' y quedan correctamente fuera de un filtro demográfico, sin generar valores nulos ni errores.

---

7. Seguimiento: cómo se cumplieron los compromisos en el Objetivo 2

Los puntos 3 (constructo unificado) y 4 (datasets sintéticos) comprometieron cómo se haría el modelado. El notebook 09 los materializa sobre la propia estrella:

- **La política se aplica desde la base de datos.** El notebook lee uso_modelado de vw_dim_dataset y modela únicamente las fuentes 'incluido': 8 tareas sobre 9 fuentes (Dreaddit train y test forman una tarea). Si una fuente pasa a 'excluido', el notebook la omite sin tocar el código.
- **Cada modelo predice su variable nativa y se lee en la capa armonizada.** Los resultados se cargan en dwh_modelo_resultados, enlazada a dim_dataset por id_dataset y con la columna lectura_capa_armonizada (p. ej. GAD-7 ≥ 10 equivale a nivel Alto). Es la segunda tabla de hechos de la constelación de consumo (Figura 3): comparte vw_dim_dataset con la estrella, de modo que un mismo segmentador filtra registros y resultados.
- **Resultado.** En las fuentes con señal real el AUC del mejor modelo se sitúa entre 0,73 y 0,84: se puede anticipar el estrés mejor que el azar, no predecirlo con precisión individual.

- **Hallazgo de validez.** El dataset Depression Student alcanza AUC ≈ 0,998. Ninguna variable aislada supera 0,77, pero una combinación lineal reproduce la etiqueta casi sin error, patrón típico de etiquetas generadas por una fórmula. No se afirma que sea sintético, pero es un indicio serio: se reporta con cautela y se propone consultarlo con el tutor. Si se confirma, basta una sentencia UPDATE sobre dim_dataset (uso_modelado = 'excluido') para que la exclusión se propague a la estrella, a Power BI y al notebook.

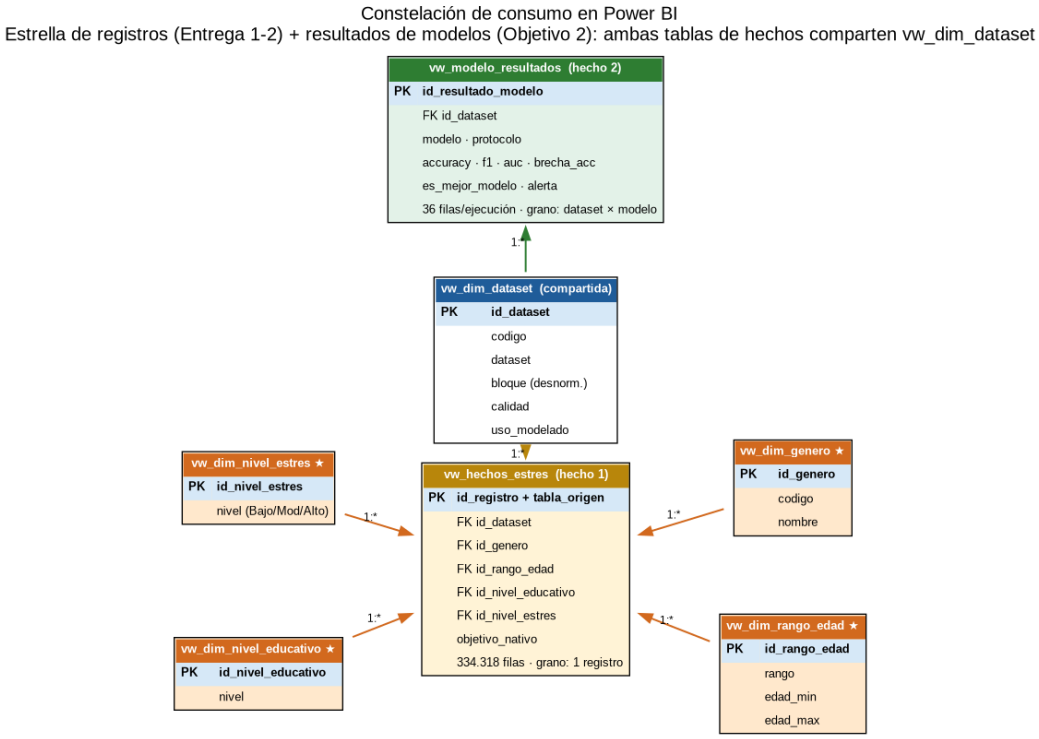


Figura 3. Constelación de consumo: la estrella de registros y los resultados de modelado comparten vw_dim_dataset.

El detalle metodológico y los resultados por dataset están en el documento de síntesis del Objetivo 2.

8. Entregables y orden de ejecución definitivo

Orden en el que debe ejecutarse la cadena completa sobre una base vacía (phpMyAdmin para los .sql, Jupyter para los notebooks, con XAMPP en verde):

Paso	Archivo	Herramienta	Qué hace
1	modelo_datos_mysql_v2.sql	phpMyAdmin	Crea la base tfm_estres_estudiantil_2 y las 19 tablas (7 dimensiones + 12 hechos).
2	esquema_estrella_powerbi.sql (definitivo)	phpMyAdmin	Crea las 6 vistas de la estrella.
3	07_carga_datos_mysql.ipynb	Jupyter	Carga los 334.318 registros de los 12 datasets.
4	modelo_dwh_mysql.sql	phpMyAdmin	Crea las 7 tablas del datawarehouse (Entrega 2).
5	08_etl_transformaciones_kpis_v2.ipynb	Jupyter	Transformaciones T1-T5 y 6 KPIs con histórico.
6	modelo_dwh_modelos.sql	phpMyAdmin	Crea dwh_modelo_resultados y la vista vw_modelo_resultados.

Paso	Archivo	Herramienta	Qué hace
7	09_modelado_objetivo2.ipynb	Jupyter	Modelado (8 tareas), serialización y carga de resultados al DWH.

- **modelo_datos_mysql_v2.sql** — modelo físico corregido: 19 tablas, claves primarias legibles, 4 dimensiones conformes, tabla de gobernanza dim_mapeo_estres y columna uso_modelado.
- **modelo_datos_ERD_v2.png** — diagrama entidad-relación con las dimensiones conformes destacadas.
- **esquema_estrella_powerbi.sql** (definitivo) y **esquema_estrella_powerbi_12fuentes.png** (diagrama definitivo) — capa de consumo con las 12 fuentes; el diagrama inicial queda como referencia.
- **esquema_constelacion_powerbi.png** y **modelo_dwh_modelos.sql** — integración de los resultados del Objetivo 2 como segunda tabla de hechos.
- **06_armonizacion_dimensiones_conformes.ipynb** y **07_carga_datos_mysql.ipynb** — armonización y carga de los doce datasets.
- **Este documento** — trazabilidad observación → acción → entregable → verificación.

Con estas correcciones, la arquitectura resuelve los fallos críticos señalados —silos, claves ilegibles, indefinición del constructo y riesgo de contaminación sintética del modelado—, está implementada y verificada sobre datos reales, y sustenta tanto el modelado del Objetivo 2 como el Dashboard Multidimensional del Objetivo 3.