TRABAJO FINAL DE MÁSTER — Business Analytics e Inteligencia Artificial

Análisis multidimensional del estrés estudiantil mediante Business Analytics e Inteligencia Artificial

Andrés Francisco García Grajales • Obed Isaí Alvarado Núñez • Roberto Mario Brochero López
Raúl Cervantes Iglesias • Santiago Nicolas Viuche Pinilla

Entrega 2: ETL, transformaciones y KPIs sobre un datawarehouse en estrella

Esta entrega construye el datawarehouse del proyecto como un **esquema en estrella** y lo alimenta con un proceso ETL en Python que lee de MySQL y escribe en MySQL. El resultado son cinco tablas de hechos con sus transformaciones, seis KPIs con histórico de ejecuciones y la prueba de que todas las claves apuntan a las dimensiones conformes que pidió el tutor en la retroalimentación de la Entrega I.

1. Arquitectura: de las tablas ingestadas al datawarehouse

Capa	Objetos	Papel en el ETL
Ingesta (Entrega 1)	19 tablas normalizadas cargadas por el notebook 07 con los 334.318 registros de los 12 datasets	**Origen.** Cada dataset conserva sus columnas propias en su tabla.
Capa de consumo	Vistas vw_hechos_estres y vw_dim_dataset (esquema_estrella_powerbi.sql)	**Origen de T1.** Une los 12 datasets por sus cinco claves conformes y marca cuáles se modelan.
Datawarehouse (esta entrega)	8 tablas dwh_* creadas por dwh_estrella.sql: 5 hechos de transformación, catálogo e histórico de KPIs, y resultados del Objetivo 2	**Destino.** Hechos que solo guardan claves hacia las dimensiones conformes y sus medidas.

Las dimensiones conformes (género, rango de edad, nivel educativo, nivel de estrés, dataset, bloque y subreddit) son **las mismas tablas** que usan la ingesta y la estrella: por eso un filtro como «Mujeres de 18-25 años» actúa a la vez sobre todos los hechos. Cada tabla de hechos del datawarehouse declara sus claves foráneas con restricciones reales de MySQL, de modo que no pueden existir registros huérfanos.

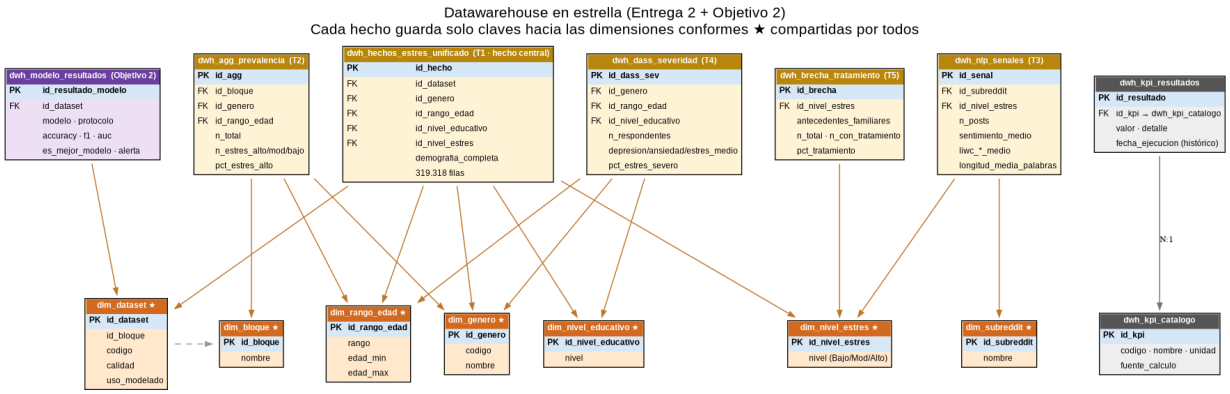


Figura 1. Datawarehouse en estrella: hechos (arriba) y dimensiones conformes ★ (abajo).

2. Transformaciones

El notebook **08_etl_transformaciones_kpis_v4.ipynb** aplica cinco transformaciones de tipos distintos. Todas extraen de MySQL, transforman con pandas y cargan en una tabla nueva. Al empezar vacía las

cinco tablas, de modo que puede relanzarse sin duplicar datos.

#	Transformación	Tipo	Destino	Filas	Resultado destacado
T1	Registros de las 9 fuentes con señal real, desde la estrella	Integración	dwh_hechos_estres_unificado	319.318	La validación psicológica aporta el 94 % del volumen.
T2	Prevalencia de estrés por bloque × género × edad	Agregación	dwh_agg_prevalencia	49	En los grupos grandes el estrés Alto va del 14,7 % al 52,3 %; 18 grupos tienen menos de 30 registros.
T3	Señales lingüísticas de Dreaddit por subreddit y nivel	Resumen estadístico	dwh_nlp_senales	20	En los 10 subreddits, más ansiedad LIWC y menos sentimiento con estrés.
T4	DASS 18-25 por género × nivel educativo, con % de estrés severo	Pivote + umbral clínico	dwh_dass_severidad	12	«Otro» con secundaria o menos: estrés medio 38,4 y 50 % en rango severo.
T5	Tratamiento según estrés creciente × antecedentes familiares	Contingencia	dwh_brecha_tratamiento	6	≈ 35 % sin antecedentes frente a ≈ 72 % con ellos, en los tres niveles de estrés.

3. KPIs

Los seis indicadores se calculan en Python y se guardan en **dwh_kpi_resultados**, una fila por KPI y ejecución con su fecha, de modo que el valor nunca se sobrescribe. Su definición está en dwh_kpi_catalogo y en el documento KPIs_TFM.docx.

KPI	Valor	Unidad	Interpretación
Tasa de estrés Alto global	33,68	%	Uno de cada tres registros está en estrés Alto.
Brecha de género en ansiedad	2,89	puntos	Las mujeres puntúan 31,0 frente a 28,1 de los hombres (DASS, 18-25).
Índice de riesgo crítico	72,69	%	El 73 % de quienes reportan pensamientos suicidas presenta depresión. Ver nota de validez en KPIs_TFM.docx.
Tasa de búsqueda de tratamiento	49,41	%	La mitad de los estudiantes ha buscado tratamiento.
Poder discriminante LIWC	2,58	ratio	El vocabulario de ansiedad es 2,6 veces mayor en los textos con estrés.
Cobertura demográfica	17,01	%	Solo el 17 % de los registros tiene género y edad reportados.

4. Calidad y verificación

- **Integridad de la estrella:** el notebook comprueba 14 relaciones entre hechos y dimensiones y exige 0 claves huérfanas.
- **Cuadre con la estrella:** los registros de las fuentes «incluido» de vw_hechos_estres deben sumar lo mismo que T1: 334.318 − 15.000 sintéticos = 319.318.
- **Requisitos comprobados al inicio:** si falta una tabla, una vista o los datos, el notebook se detiene e indica qué script ejecutar.
- **Limitación conocida de la ingesta:** 67 de los 39.767 respondentes del DASS (0,17 %) no contestaron el género y la ingesta los clasificó como «Otro» en lugar de «No reportado». El efecto es mínimo (0,02 puntos en la cobertura demográfica) y se corregiría en una recarga futura.

El tipo de problema de aprendizaje de cada dataset y el feature engineering se documentan en el notebook del Objetivo 2 (09), que es donde se utilizan.

---

5. Entregables

Archivo	Contenido
dwh_estrella.sql	Crea las 8 tablas del datawarehouse con sus claves foráneas (ejecutar una vez).
08_etl_transformaciones_kpis_v4.ipynb	Notebook documentado: transformaciones T1-T5, KPIs y verificaciones.
dwh_estrella_ERD.png	Diagrama del datawarehouse en estrella.
KPIs_TFM.docx	Definición de cada KPI.
Sintesis_Entrega2_ETL_KPIs.pdf	Este documento.