TRABAJO FINAL DE MÁSTER — Business Analytics e Inteligencia Artificial

Análisis multidimensional del estrés estudiantil mediante Business Analytics e Inteligencia Artificial

Andrés Francisco García Grajales • Obed Isaí Alvarado Núñez • Roberto Mario Brochero López
Raúl Cervantes Iglesias • Santiago Nicolas Viuche Pinilla

Objetivo 2: Modelado predictivo del estrés (clasificación y NLP)

1. Alcance y relación con las entregas

El Objetivo 2 de la propuesta es *desarrollar modelos de inteligencia artificial para la predicción del estrés, con clasificación sobre datos estructurados y procesamiento de lenguaje natural sobre datos textuales, manteniendo un análisis independiente por dataset*. Según el Alcance oficial del máster, el Machine Learning es la parte opcional de la Entrega 3. Este trabajo se apoya en lo ya construido: las fuentes y su calidad (Entrega 1), el datawarehouse y los KPIs (Entrega 2) y la capa de consumo en estrella (retroalimentación de la Entrega I), con la que se integra como se explica en la sección 2.

Todo el código está en el notebook **09_modelado_objetivo2.ipynb**. Las cifras de este documento proceden de su ejecución de validación sobre los mismos CSV del proyecto (semilla 42; scikit-learn 1.8.0, XGBoost 3.4.1) y pueden variar en las milésimas con otras versiones de las librerías.

---

2. Integración con el esquema estrella

Tras definir la estrella como capa de consumo (6 vistas, 12 fuentes, 334.318 registros), se validó qué cambia en el Objetivo 2. **La lógica de modelado no cambia**: cada dataset se modela de forma independiente a partir de sus CSV. Lo que sí cambia son tres puntos de contacto con la estrella:

- **La política de modelado se lee de la base de datos.** El notebook consulta uso_modelado en vw_dim_dataset y modela únicamente las fuentes 'incluido'. Si una fuente pasa a 'excluido', se omite sin tocar el código. Si no hay conexión a MySQL, aplica la política por defecto (verificado en ambos modos con resultados idénticos).
- **Los resultados vuelven al datawarehouse.** Se cargan en dwh_modelo_resultados (creada por dwh_estrella.sql), con id_dataset como clave foránea hacia dim_dataset y la columna lectura_capa_armonizada que indica cómo leer cada resultado en el constructo unificado.
- **Una segunda tabla de hechos, sin tocar la estrella.** vw_modelo_resultados (grano: dataset × modelo × ejecución) comparte con vw_hechos_estres la dimensión vw_dim_dataset, formando una constelación: en Power BI, un mismo segmentador de bloque, calidad o uso_modelado filtra registros y resultados.

Tarea de modelado	id_dataset	Bloque	Protocolo	n
B1_ACADSTRESS	1	Factores internos	CV 5x3	140
B1_ANXIETY	2	Factores internos	Hold-out 80/20	9.302
B1_MHSURVEY	3	Factores internos	CV 5x3	87

Tarea de modelado	id_dataset	Bloque	Protocolo	n
B2_SMMH	6	Hábitos digitales	CV 5x3	481
B3_DEPSTUDENT	10	Percepción emocional	CV 5x3	502
B4_DASS	11	Validación psicológica	Hold-out 80/20	23.039
B4_MENTALHEALTH	12	Validación psicológica	Hold-out 80/20	54.207
B3_DREADDIT	8 (y 9)	Percepción emocional	Train/Test original	3.549

Dreaddit (train, id 8, y test, id 9) es una única tarea y se registra con id_dataset = 8; sus métricas se miden sobre la partición de prueba. Los tres datasets sintéticos (ids 4, 5 y 7) no se modelan.

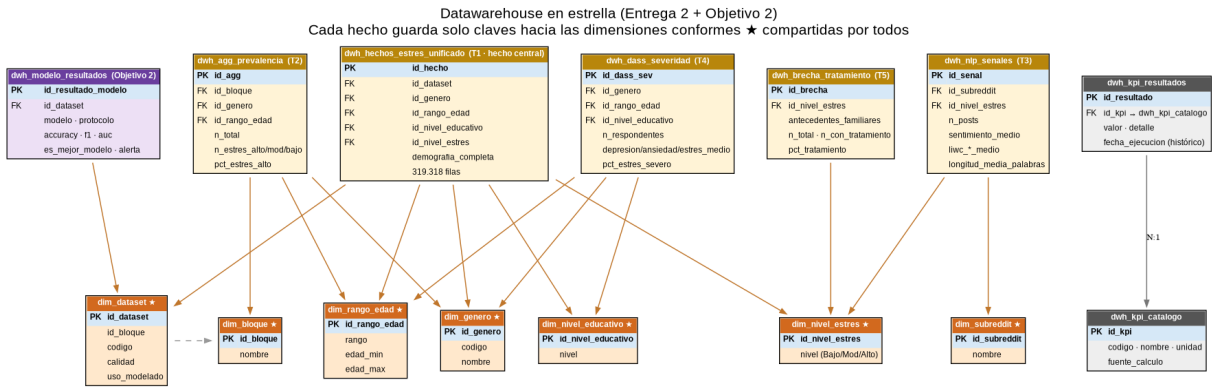


Figura 1. Datawarehouse en estrella: los resultados de modelado (violeta) comparten dim_dataset con el resto de hechos.

3. Diseño metodológico

Decisión	Qué se hizo	Por qué
Fuentes	9 fuentes 'incluido' → 8 tareas. Los 3 sintéticos quedan fuera.	Exigencia del tutor: los datos sintéticos restan validez científica.
Independencia	Un modelo por dataset, sin fusionar fuentes.	Metodología de análisis en paralelo.
Candidatos	Baseline + Regresión Logística + Random Forest + XGBoost. NLP: además TF-IDF con LR, SVM y Naive Bayes, y un híbrido con LIWC.	Días 6 y 8 del máster.
Evaluación	n < 1000: validación cruzada estratificada 5×3 (15 evaluaciones). n ≥ 1000: hold-out 80/20 estratificado. Dreaddit: partición original.	Con 87 filas un único hold-out es inestable (Día 5: sobreajuste).
Métrica principal	AUC; F1 y Accuracy se comparan siempre contra el baseline.	El Accuracy engaña con clases desbalanceadas.
Fuga de datos	Se excluyen las variables que construyen el target (ítems GAD-7, ítems DASS, 'anxiety' en MH Survey, confidence y subreddit en Dreaddit).	Evita resultados triviales.
Ética	Religión, orientación sexual y raza no se usan como predictores.	No se modelan atributos sensibles.
Deep learning	No se aplica (MLP, LSTM: Días 9-10).	Con datos tabulares de 87 a 54.000 filas, regresión y árboles son el punto de partida estándar; queda como línea futura.
Industrialización	Pipeline completo (preprocesado + modelo) en .pkl y .json.	Día 11.

Cómo leer las métricas. *Accuracy*: proporción de aciertos (engaña si una clase domina). *F1*: equilibrio entre precisión y exhaustividad de la clase de interés (en multiclase, promedio macro). *AUC*: probabilidad de que el modelo puntúe más alto a un caso positivo que a uno negativo; 0,5 es el azar y 1

la separación perfecta. *Brecha*: Accuracy de entrenamiento menos Accuracy de prueba; valores superiores a ≈ 0,15 indican sobreajuste. El *baseline* predice siempre la clase mayoritaria y fija el suelo que cualquier modelo debe superar.

---

4. Modelado por dataset

Cada tarea se documenta con una ficha, la comparación de los cuatro candidatos, la matriz de confusión y la importancia de variables del mejor modelo, y su análisis.

B1_ACADSTRESS — estrés académico

Fuente	Factores internos · id_dataset 1 · 140 registros
Target	Indice de estres academico (1-5)
Clases	1: 4,3 % · 2: 6,4 % · 3: 25,7 % · 4: 40,0 % · 5: 23,6 %
Protocolo	CV 5x3
Variables	5 numéricas + 3 categóricas
Feature Engineering	Label Encoding de la etapa académica (orden natural) · One-Hot de entorno, estrategia de afrontamiento y hábitos · derivada presion_total = pares + hogar + competencia.
Más influyentes	presion_total (0.25), competencia (0.20), presion_pares (0.15), presion_hogar (0.12)
Lectura armonizada	Indice 1-5: 1-2 Bajo, 3 Moderado, 4-5 Alto

Modelo	Accuracy	F1	AUC	± AUC	Brecha
Baseline (clase mayoritaria)	0.400	0.114	0.500	0.000	0.000
Regresion Logistica	0.350	0.338	0.715	0.056	0.184
Random Forest	0.395	0.383	0.730	0.035	0.433
XGBoost	0.388	0.369	0.672	0.058	0.548

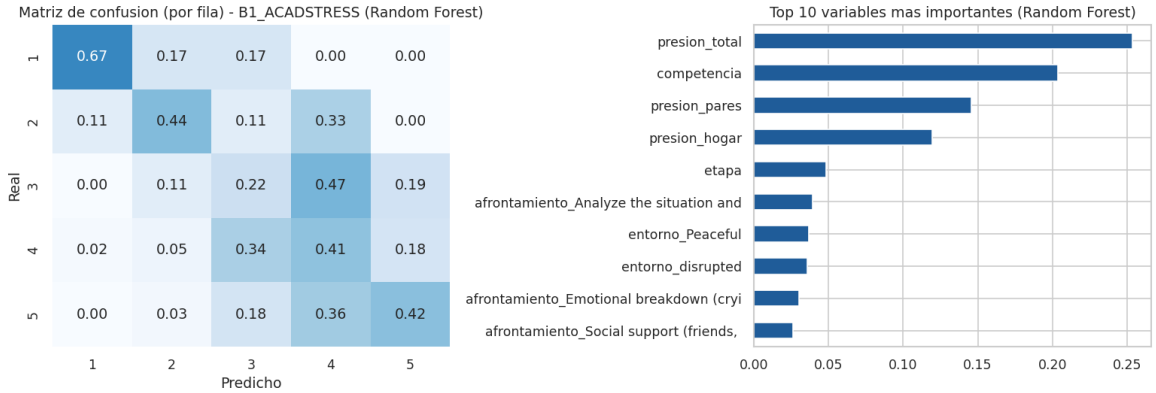


Figura. B1_ACADSTRESS: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

El mejor modelo (Random Forest) alcanza un AUC ≈ 0,73, pero su Accuracy (≈ 0,40) no supera al baseline (0,40): ordena los niveles de estrés mejor que el azar, pero no acierta el nivel exacto. La brecha de ≈ 0,43 revela sobreajuste fuerte. Con 140 filas y clases de apenas 6 y 9 casos, predecir cinco niveles es demasiado ambicioso: el resultado es exploratorio. La variable derivada presion_total encabeza la importancia (≈ 0,25), lo que respalda el hallazgo del Objetivo 1 sobre la presión académica. Mejora posible: trabajar con los tres niveles de la capa armonizada o ampliar la muestra.

B1_ANXIETY — ansiedad GAD-7 (estudiantes)

Fuente	Factores internos · id_dataset 2 · 9.302 registros
Target	GAD-7 >= 10
Clases	No alto (<10): 82,7 % · Alto (>=10): 17,3 %
Protocolo	Hold-out 80/20
Variables	7 numéricas + 4 categóricas
Feature Engineering	Fuga evitada: los ítems GAD1-7 y GADE se excluyen porque GAD_T es su suma · derivadas con cortes clínicos (swl_insatisfecho si SWL ≤ 14; spin_alto si SPIN ≥ 19) · horas_juego acotada a 112 h/semana (regla de calidad R4).
Más influyentes	spin (0.27), swl (0.23), horas_juego (0.16), edad (0.09)
Lectura armonizada	GAD-7 >= 10 equivale a nivel Alto

Modelo	Accuracy	F1	AUC	Brecha
Baseline (clase mayoritaria)	0.827	0.000	0.500	0.000
Regresion Logistica	0.730	0.453	0.764	0.004
Random Forest	0.798	0.400	0.745	0.145
XGBoost	0.829	0.299	0.754	0.039

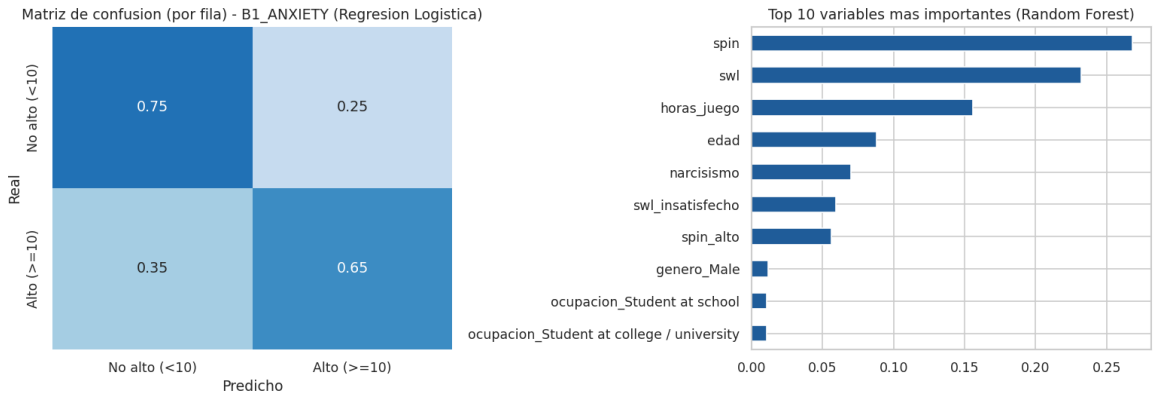


Figura. B1_ANXIETY: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

Es el ejemplo de la trampa del Accuracy: el baseline "nunca hay ansiedad alta" obtiene un 83 % de Accuracy con F1 = 0, de modo que supera en Accuracy a todos los modelos sin detectar un solo caso. La Regresión Logística (Accuracy ≈ 0,73) logra F1 ≈ 0,45 y AUC ≈ 0,77, el mejor equilibrio, con sobreajuste casi nulo (brecha ≈ 0,00 frente a ≈ 0,15 del Random Forest): gana el modelo más simple. SPIN (ansiedad social) y SWL (satisfacción vital) dominan la importancia, coherente con el Objetivo 1. Limitación: la población original son jugadores online.

B1_MHSURVEY — salud mental universitaria

Fuente	Factores internos · id_dataset 3 · 87 registros
Target	Depresion autoreportada (3 niveles)
Clases	Bajo: 31,0 % · Moderado: 24,1 % · Alto: 44,8 %
Protocolo	CV 5x3
Variables	13 numéricas + 5 categóricas
Feature Engineering	Fuga evitada: 'anxiety' se excluye (r = 0,84 con el target) · cgpa y average_sleep pasan de rangos de texto a orden numérico (Label Encoding ordinal) · One-Hot de residencia y año · derivadas carga_presion (interacción) y bienestar = satisfacción – aislamiento.
Más influyentes	aislamiento (0.16), bienestar (0.13), financiero (0.09), inseguridad (0.08)
Lectura armonizada	Depresion 1-5 mapeada a Bajo / Moderado / Alto

Modelo	Accuracy	F1	AUC	± AUC	Brecha
Baseline (clase mayoritaria)	0.448	0.206	0.500	0.000	-0.000
Regresion Logistica	0.621	0.572	0.771	0.069	0.225
Random Forest	0.614	0.509	0.764	0.071	0.378
XGBoost	0.621	0.551	0.789	0.069	0.379

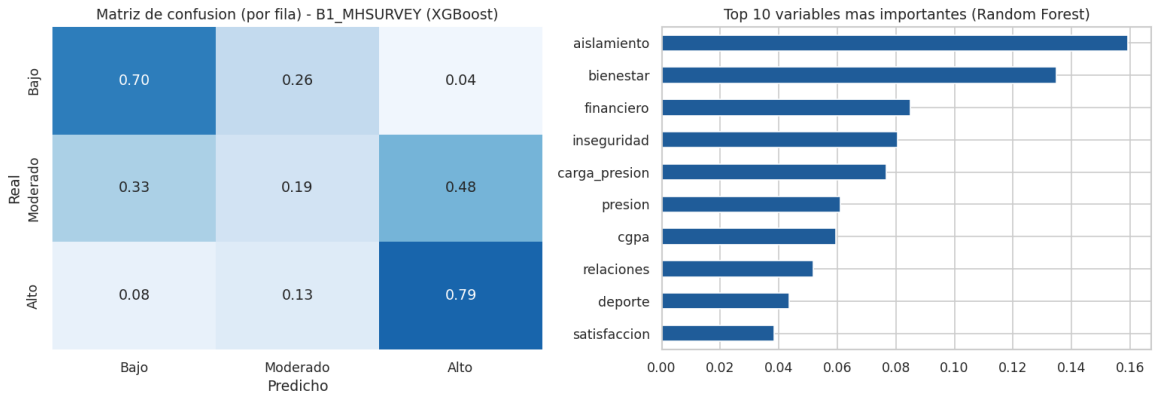


Figura. B1_MHSURVEY: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

AUC ≈ 0,76-0,79 y Accuracy ≈ 0,62 frente a 0,45 del baseline: hay señal real. Sin embargo, la desviación entre repeticiones (±0,07) es del tamaño de las diferencias entre modelos, así que XGBoost, Regresión Logística y Random Forest son estadísticamente indistinguibles con n = 87; los árboles sobreajustan (brecha ≈ 0,38). Lo más relevante: la variable derivada bienestar queda segunda en importancia, tras aislamiento, lo que confirma al aislamiento social como predictor central, igual que en el Objetivo 1.

B2_SMMH — redes sociales y salud mental

Fuente	Hábitos digitales · id_dataset 6 · 481 registros
Target	Se siente deprimido/a >= 4
Clases	Bajo (<4): 54,1 % · Alto (>=4): 45,9 %
Protocolo	CV 5x3
Variables	23 numéricas + 3 categóricas
Feature Engineering	Se excluye la pregunta 19 (interés en actividades) por ser un síntoma del mismo constructo · One-Hot de las plataformas (multi-selección separada en dummies) · tiempo_diario ordinal · derivadas uso_ansioso = (inquietud + distracción fácil + preocupación) / 3 e impacto_social = (comparación + validación) / 2.
Más influyentes	preocupacion (0.13), uso_ansioso (0.10), dificultad_concentracion (0.08), impacto_social (0.07)
Lectura armonizada	Valor >= 4 equivale a nivel Alto

Modelo	Accuracy	F1	AUC	± AUC	Brecha
Baseline (clase mayoritaria)	0.540	0.000	0.500	0.000	-0.000
Regresion Logistica	0.736	0.726	0.792	0.037	0.033
Random Forest	0.741	0.730	0.793	0.038	0.233
XGBoost	0.702	0.680	0.778	0.043	0.296

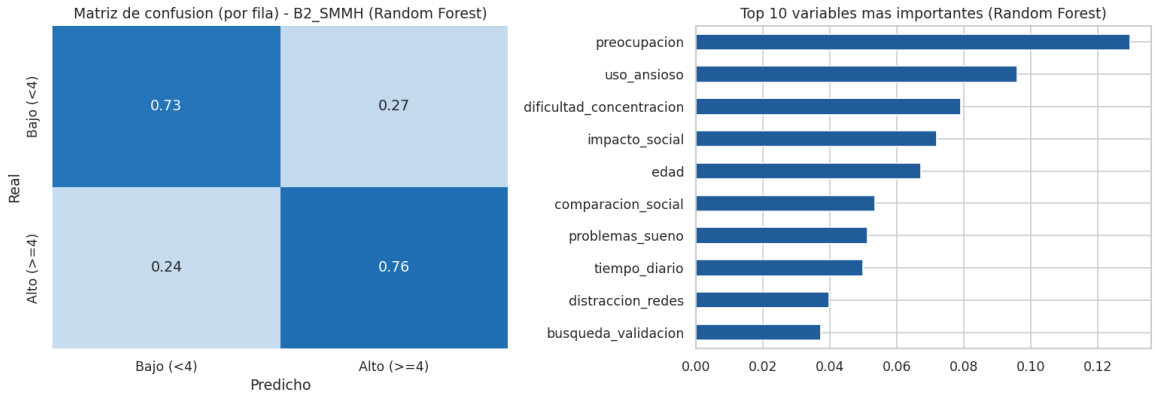


Figura. B2_SMMH: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

Es la fuente de hábitos digitales con señal real: AUC ≈ 0,79 y Accuracy ≈ 0,74 frente a 0,54; Regresión Logística y Random Forest empatan, así que el patrón es esencialmente lineal. Dos de las cuatro variables más importantes son derivadas (uso_ansioso, impacto_social), y ni el tiempo diario ni las plataformas figuran entre las primeras: importa el patrón de uso (preocupación, concentración, comparación), no cuánto se usa. uso_ansioso (r ≈ 0,56) no supera a su mejor componente, la preocupación (r ≈ 0,59); aporta estabilidad al promediar tres señales.

B3_DEPSTUDENT — depresión estudiantil (con alerta)

Fuente	Percepción emocional · id_dataset 10 · 502 registros
Target	Depression (Yes/No)
Clases	Sin depresion: 49,8 % · Con depresion: 50,2 %
Protocolo	CV 5x3
Variables	10 numéricas + 1 categóricas
Feature Engineering	Label Encoding ordinal de sueño y dieta · binarias para pensamientos suicidas y antecedentes · derivada riesgo_alto (presión ≥ 4 y estrés financiero ≥ 4).
Más influyentes	pens_suicidas (0.22), presion (0.21), edad (0.12), satisfaccion (0.10)
Lectura armonizada	No = Bajo, Yes = Alto

Modelo	Accuracy	F1	AUC	± AUC	Brecha
Baseline (clase mayoritaria)	0.502	0.668	0.500	0.000	0.000
Regresion Logistica	0.979	0.979	0.998	0.002	0.012
Random Forest	0.900	0.903	0.974	0.014	0.098
XGBoost	0.929	0.930	0.987	0.008	0.071

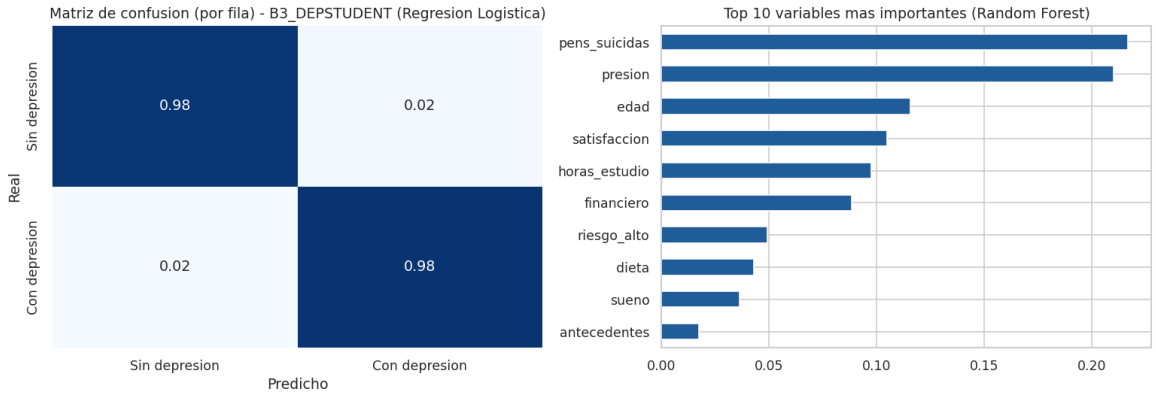


Figura. B3_DEPSTUDENT: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

La Regresión Logística obtiene AUC ≈ 0,998 y Accuracy ≈ 0,98, un resultado demasiado perfecto para datos clínicos reales. Se trata con cautela y se analiza en la sección 6.

B4_DASS — DASS-42, 18-25 años

Fuente	Validación psicológica · id_dataset 11 · 23.039 registros
Target	Nivel de estres DASS-42 (baremos)
Clases	Bajo: 28,8 % · Moderado: 35,7 % · Alto: 35,5 %
Protocolo	Hold-out 80/20
Variables	8 numéricas + 4 categóricas
Feature Engineering	Ningún ítem DASS como predictor (los de estrés definen el target) · las 10 respuestas TIPI se convierten en las 5 puntuaciones Big Five (invirtiendo los ítems inversos con 8 – x) · One-Hot de género, entorno de infancia, lengua nativa y estado civil · religión, orientación y raza excluidas por ética.
Más influyentes	estab_emocional (0.31), responsabilidad (0.10), extraversion (0.10), apertura (0.10)
Lectura armonizada	Baremos DASS: <=28 Bajo, 29-39 Moderado, >=40 Alto

Modelo	Accuracy	F1	AUC	Brecha
Baseline (clase mayoritaria)	0.357	0.175	0.500	0.000
Regresion Logistica	0.569	0.567	0.762	-0.003
Random Forest	0.564	0.566	0.754	0.383
XGBoost	0.579	0.584	0.762	0.032

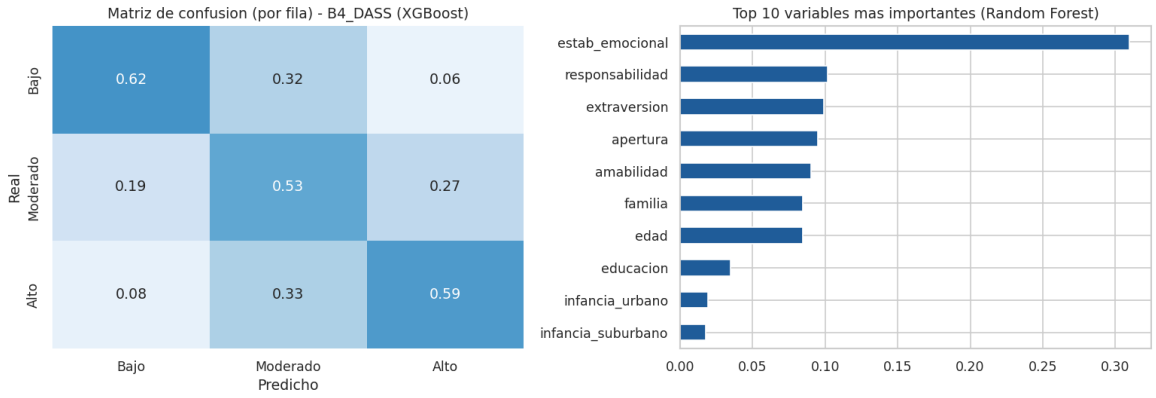


Figura. B4_DASS: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

Predecir el estrés solo a partir del perfil y la personalidad da AUC ≈ 0,76 y Accuracy ≈ 0,58 frente a 0,36 del baseline. La estabilidad emocional domina con diferencia (importancia ≈ 0,31, el triple que cualquier otro rasgo), coherente con la relación psicológica entre neuroticismo y estrés. Regresión Logística y XGBoost empatan, y XGBoost apenas sobreajusta (brecha ≈ 0,03) frente al Random Forest (≈ 0,38): la regularización importa. Con ≈ 0,58 de Accuracy en tres clases, la personalidad explica una parte del estrés, no su totalidad.

B4_MENTALHEALTH — búsqueda de tratamiento (estudiantes)

Fuente	Validación psicológica · id_dataset 12 · 54.207 registros
Target	Ha buscado tratamiento (Yes/No)
Clases	Sin tratamiento: 50,6 % · Con tratamiento: 49,4 %
Protocolo	Hold-out 80/20
Variables	5 numéricas + 9 categóricas
Feature Engineering	El target es una conducta (ha buscado tratamiento), no un nivel de estrés · Label Encoding ordinal de días en casa, estrés creciente y cambios de humor · One-Hot del resto · derivada vulnerabilidad = antecedentes + historial propio.
Más influyentes	antecedentes (0.27), conoce_opciones_Yes (0.16), vulnerabilidad (0.11), conoce_opciones_No (0.06)
Lectura armonizada	Conducta de busqueda de ayuda (no es nivel de estres): alimenta el KPI de tratamiento

Modelo	Accuracy	F1	AUC	Brecha
Baseline (clase mayoritaria)	0.506	0.000	0.500	0.000
Regresion Logistica	0.703	0.708	0.765	-0.003
Random Forest	0.698	0.712	0.729	0.022
XGBoost	0.718	0.728	0.769	-0.004

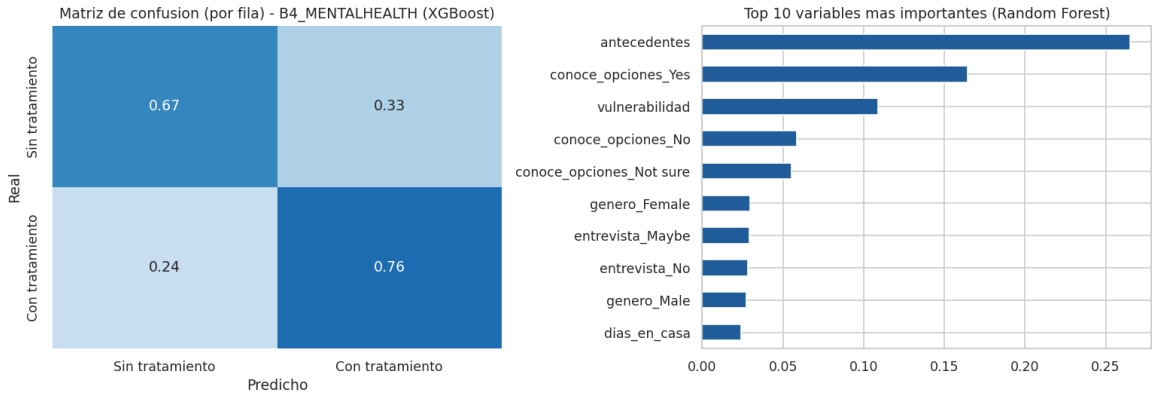


Figura. B4_MENTALHEALTH: matriz de confusión (por fila) e importancia de variables del mejor modelo (en negrita en la tabla).

XGBoost: AUC ≈ 0,77 y Accuracy ≈ 0,72 frente a 0,51, sin sobreajuste (brecha ≈ 0,00). Los antecedentes familiares encabezan la importancia (≈ 0,27) y estres_creciente no figura entre las primeras: el modelo reproduce el hallazgo del Objetivo 1 (el estrés percibido no mueve la búsqueda de ayuda; la familiaridad con la salud mental sí). Cautela: conoce_opciones (≈ 0,16) puede ser consecuencia de estar en tratamiento y no su causa (causalidad inversa).

---

5. NLP: detección de estrés en texto (B3_DREADDIT)

Se comparan tres enfoques sobre la partición train/test original (2.834 textos de entrenamiento y 715 de prueba tras aplicar la regla de calidad R7, que excluye los fragmentos '#NAME?'; la regla R6 alinea las columnas por nombre; no hay solapamiento de post_id entre particiones): (1) las 105 variables psicolingüísticas precalculadas (LIWC, DAL, legibilidad, sentimiento); (2) TF-IDF de unigramas y bigramas con tres clasificadores; (3) un híbrido de ambos. No se eliminan las stop-words porque los pronombres ('I', 'me') son precisamente señal de estrés. Se excluyen confidence (no existe al predecir), subreddit (casi equivale a la etiqueta) y las variables social_*.

Modelo	Accuracy	F1	AUC	Brecha
Baseline (clase mayoritaria)	0.516	0.681	0.500	0.008
LIWC + Regresion Logistica	0.744	0.757	0.835	0.042
LIWC + Random Forest	0.754	0.770	0.834	0.245
LIWC + XGBoost	0.732	0.752	0.835	0.240
TF-IDF + Regresion Logistica	0.716	0.733	0.822	0.217
TF-IDF + SVM lineal	0.732	0.745	0.820	0.265
TF-IDF + Naive Bayes	0.719	0.766	0.831	0.225
Hibrido (TF-IDF + LIWC) + RegLog	0.748	0.762	0.838	0.085

Los tres enfoques rinden de forma muy parecida (AUC 0,82-0,84 y Accuracy 0,72-0,75, frente a 0,52 del baseline). El híbrido es el mejor, pero con 715 textos de prueba las diferencias de ≈ 0,01 no son concluyentes: una Regresión Logística sobre LIWC (AUC 0,835) iguala a XGBoost. Los modelos sobre TF-IDF sobreajustan más (brecha 0,22-0,27) que el híbrido (0,08) y que la regresión sobre LIWC (0,04). El F1 del baseline (0,68) es alto porque predice siempre la clase mayoritaria 'estrés': otra muestra de por qué se usa el AUC.

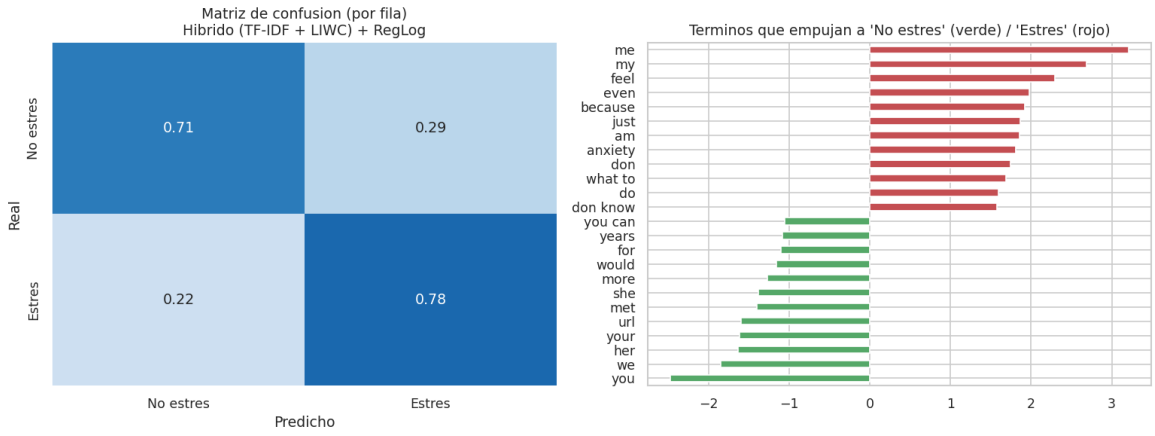


Figura. Matriz de confusión del mejor modelo y términos que más empujan hacia cada clase.

Qué dice el lenguaje. El modelo detecta el 78 % de los textos con estrés (recall) y descarta correctamente el 71 % de los que no lo tienen. Los términos que más empujan hacia *estrés* son me, my, feel, even, because, just, am: lenguaje centrado en uno mismo. Hacia *no estrés*: you, we, her, your, url, met, she: lenguaje dirigido a otras personas. Coincide con el Objetivo 1 (la primera persona aparece un 10,8 % en los posts de estrés frente a un 7,1 %) y es un marcador clásico de rumiación.

Despliegue. El mejor modelo necesita variables LIWC (diccionario con licencia) que no se pueden calcular sobre texto nuevo. Por eso se guarda también modelo_B3_DREADDIT_solo_texto.pkl (TF-IDF + Regresión Logística, AUC 0,82), que solo requiere el texto; el notebook incluye un ejemplo de uso. **Limitación:** el corpus procede de subreddits de PTSD, relaciones y violencia doméstica; el estrés capturado es relacional y clínico, no estrictamente académico.

---

6. Alerta: un resultado demasiado perfecto (B3_DEPSTUDENT)

La Regresión Logística obtiene AUC ≈ 0,998 y Accuracy ≈ 0,98 con diez variables gruesas. Ningún dataset real de salud mental alcanza esa separabilidad. Para distinguir entre una fuga de datos y otra causa, el notebook ejecuta un diagnóstico: mide el AUC de cada variable por separado y el de árboles de

decisión muy simples.

Variable (por separado)	AUC
presion	0.769
pens_suicidas	0.733
financiero	0.668
satisfaccion	0.666
edad	0.625
horas_estudio	0.613
Árbol de profundidad 2	0.826
Árbol de profundidad 4	0.900
Regresión Logística (todas las variables)	0.998

Ninguna columna filtra la etiqueta (la mejor, la presión académica, llega a 0,77), pero la combinación lineal de varias la reproduce casi sin error: patrón típico de etiquetas generadas por una fórmula. No puede afirmarse que el dataset sea sintético, pero es un indicio serio. Dado que la política acordada es no modelar datos sintéticos, el resultado se reporta con cautela y no se usa como evidencia sustantiva. Este dataset sustenta además el KPI de riesgo crítico (72,7 %). **Recomendación:** consultarlo con el tutor; si se decide excluirlo, basta ejecutar UPDATE dim_dataset SET uso_modelado='excluido', calidad='tecnico' WHERE codigo='B3_DEPSTUDENT', y la exclusión se propaga a la estrella, a Power BI y al notebook, que lo omitirá automáticamente.

---

7. Resumen comparativo

Dataset	Mejor modelo	Protocolo	Accuracy	Baseline	F1	AUC	Brecha
B3_DEPSTUDENT	Regresion Logistica	CV 5x3	0.979	0.502	0.979	0.998	0.012
B3_DREADDIT	Hibrido (TF-IDF + LIWC) + RegLog	Train/Test original	0.748	0.516	0.762	0.838	0.085
B2_SMMH	Random Forest	CV 5x3	0.741	0.540	0.730	0.793	0.233
B1_MHSURVEY	XGBoost	CV 5x3	0.621	0.448	0.551	0.789	0.379
B4_MENTALHEALTH	XGBoost	Hold-out 80/20	0.718	0.506	0.728	0.769	-0.004
B1_ANXIETY	Regresion Logistica	Hold-out 80/20	0.730	0.827	0.453	0.764	0.004
B4_DASS	XGBoost	Hold-out 80/20	0.579	0.357	0.584	0.762	0.032
B1_ACADSTRESS	Random Forest	CV 5x3	0.395	0.400	0.383	0.730	0.433

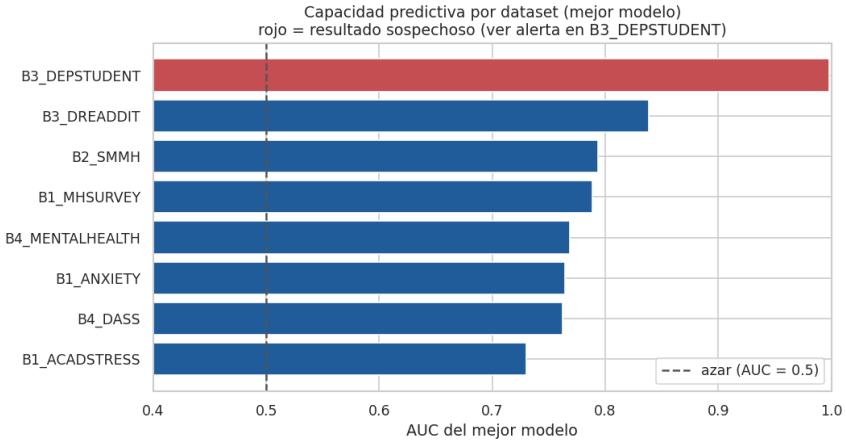


Figura. AUC del mejor modelo por dataset (línea discontinua = azar; en rojo, el resultado sospechoso).

8. Conclusiones y limitaciones

- **Hay señal predictiva real pero moderada:** AUC entre ≈ 0,73 y ≈ 0,84 en las fuentes con señal real. El estrés se puede anticipar mejor que el azar, no predecir con precisión individual.
- **Ningún algoritmo domina:** XGBoost gana 3 tareas, la Regresión Logística 3 (incluido el híbrido de NLP) y Random Forest 2; en varios casos la diferencia está dentro del ruido. En datos tabulares pequeños el modelo simple es competitivo y sobreajusta menos.
- **Los modelos confirman el Objetivo 1:** presión académica y aislamiento (Bloque 1), patrón de uso frente a tiempo de uso (Bloque 2), lenguaje autorreferencial (NLP), antecedentes familiares frente a estrés percibido en la búsqueda de ayuda, y estabilidad emocional (DASS).
- **El Accuracy por sí solo engaña:** en Anxiety el baseline lo supera sin detectar ningún caso; AUC y F1 lo evidencian.
- **Un resultado demasiado bueno es una alerta, no un éxito:** B3_DEPSTUDENT se reporta con cautela.
- **Limitaciones:** tres tareas con n < 600 (alta varianza); poblaciones distintas de la estudiantil (jugadores online, Reddit, población general); sin deep learning ni búsqueda de hiperparámetros ni ajuste de umbrales; modelos de investigación, no de diagnóstico clínico.

Siguiente paso (Entrega 3). Los resultados se consumen en Power BI desde vw_modelo_resultados como página de analítica avanzada, junto con los KPIs del datawarehouse y la estrella de registros.

---

9. Reproducibilidad y entregables

Orden de ejecución (XAMPP con MySQL en verde). Ya ejecutados en la base: modelo_datos_mysql_v2.sql, esquema_estrella_powerbi.sql y el notebook 07. A continuación: **dwh_estrella.sql → 08_etl_transformaciones_kpis_v4.ipynb → 09_modelado_objetivo2.ipynb** (ejecutar cada notebook con Kernel → Restart Kernel and Run All Cells). El notebook 09 también funciona sin base de datos (modela desde los CSV y guarda los resultados en CSV). Cada modelo se guarda como pipeline completo, de modo que puede cargarse con joblib y puntuar datos nuevos sin reentrenar.

Archivo	Contenido
09_modelado_objetivo2.ipynb	Notebook documentado: diseño, 8 tareas, NLP, diagnóstico, serialización, ejemplo de uso y carga al DWH.
dwh_estrella.sql	Datawarehouse en estrella: crea todas las tablas dwh_* (incluidas dwh_modelo_resultados y su vista).
dwh_estrella_ERD.png	Diagrama del datawarehouse en estrella, con los hechos y las dimensiones conformes.
modelos/*.pkl y *.json	9 modelos serializados (8 mejores + versión NLP solo texto) con metadata y manifest_modelos.json.
resultados_modelado_resumen.csv / _completo.csv	Métricas de todos los modelos, con id_dataset como clave de relación con la estrella.
figuras_modelado/*.png	Matriz de confusión e importancia por dataset y resumen de AUC.
Sintesis_Objetivo2_Modelado.pdf	Este documento.